

ЛЕКЦИЯ 12

Принятие решений при неопределённости

Порог уверенности — свойство задачи, а не классификатора

две части по 45

«Принятие робототехническими комплексами»

План занятия

1 Где ломается детерминированное планирование

2 MDP: политика, ценность, уравнение Беллмана

3 Оператор Беллмана как сжатие

4 Итерация по ценности и по политике

5 Числовой пример: стратегия захвата

6 POMDP: убеждение как достаточная статистика

7 Кусочная линейность и выпуклость функции ценности

8 Расчёт порога уверенности для примера A

9 Приближённые методы: точечные и онлайн

10 Обучение с подкреплением: место и границы

Синие — первая часть · янтарные — вторая часть

ЧАСТЬ 1

Решения при недетерминированных действиях

Марковские процессы принятия решений, их теория и первый числовой расчёт.

12.1

Где ломается детерминированное планирование

- Захват срывается с вероятностью 0,1–0,3 в зависимости от объекта
- Классификатор даёт «болт с уверенностью 0,72»
- Датчик наличия в захвате может ложно срабатывать
- Положение объекта известно с погрешностью
- Детерминированный план либо срывается, либо перестраивается, не используя накопленную информацию

Ключевая идея

Последний пункт главный: перепланирование выбрасывает информацию. Робот, дважды не сумевший взять предмет, знает больше, чем в первый раз, — но детерминированная модель этого не отражает.

12.2 MDP: определение

- $M = (S, A, T, R, \gamma)$: состояния, действия, переходы, вознаграждение, дисконт
- **Марковское свойство**: переход зависит только от текущего состояния и действия
- Политика $\pi : S \rightarrow A$; ценность $V^\pi(s)$ — ожидаемая дисконтированная сумма
- Дисконт $\gamma < 1$ даёт конечность суммы и предпочтение раннего результата
- Нарушение марковости означает, что состояние выбрано неудачно

Ключевая идея

Марковское свойство — проектное решение, а не свойство мира. Если оно нарушено, расширьте состояние: например, включите число уже совершённых попыток захвата.

$$V^*(s) = \max_a [R(s,a) + \gamma \sum_{s'} T(s,a,s') V^*(s')]$$

- Ценность оптимальна, если равна лучшему из «немедленно плюс дисконтированное будущее»
- Политика извлекается взятием $\arg \max$
- Оператор $B: V \mapsto BV$ задаётся правой частью
- Все алгоритмы — способы найти неподвижную точку B

$$\|BV_1 - BV_2\|_{\infty} \leq \gamma \cdot \|V_1 - V_2\|_{\infty}$$

- Доказательство: оценить разность максимумов через разность при фиксированном действии
- Нормировка $\sum T(s,a,s') = 1$ даёт коэффициент ровно γ
- По теореме Банаха: единственная неподвижная точка V^*
- Сходимость геометрическая: $\|V_k - V\| \leq \gamma^k \|V_0 - V\|$

Существование, единственность и скорость сходимости — из одного свойства

12.5 Два алгоритма

Итерация по ценности

- $V \leftarrow BV$ до сходимости
- Шаг дешёв: $O(|S|^2|A|)$
- Шагов много
- Критерий останова через $\epsilon(1-\gamma)/(2\gamma)$
- Проще в реализации


Итерация по политике

- Оценка политики: решение линейной системы
- Шаг дорог: $O(|S|^3)$
- Шагов единицы
- Конечная сходимость доказана
- Быстрее на практике

12.6 Числовой пример: стратегия захвата

- s_0 — предмет обнаружен, поза оценена грубо; s_1 — поза уточнена
- s_2 — в захвате (успех); s_3 — сдвинут, поза потеряна; s_4 — отказ
- `refine` 3 с; `grasp` из s_0 — успех 0,55; из s_1 — успех 0,88
- Восстановление из s_3 : `refine` 5 с, успех 0,8
- Штраф за отказ 60 с; минимизируем ожидаемое время

12.6 MDP стратегии захвата



Уточнить позу выгоднее на 2,34 с. Порог переключения стратегии: $p > 0,695$.

12.7 Решение

9,94 с

$V(s_1)$ — ценность состояния
«поза уточнена»

16,19 с

$V(s_3)$ — ценность состояния
«поза потеряна»

12,94 с

уточнить и захватить

15,29 с

захватить сразу

- Оптимально уточнить позу, несмотря на дополнительные 3 секунды
- Выигрыш 2,34 с в ожидаемом времени на каждый предмет



Анализ чувствительности

При какой вероятности успеха прямого захвата уточнение позы становится излишним?

А

Выше 0,55 — то есть уже сейчас

В

Выше 0,70

С

Выше 0,88

Д

Никогда: уточнение всегда полезно



Анализ чувствительности

При какой вероятности успеха прямого захвата уточнение позы становится излишним?

A

Выше 0,55 — то есть уже сейчас

B

Выше 0,70

C

Выше 0,88

D

Никогда: уточнение всегда полезно

Ответ. Выше 0,695. Решаем $8 + (1-p) \cdot 16,193 < 12,943$, получаем $p > 0,695$. Это конкретный порог для инженерного решения.

П Е Р Е Р Ы В

Конец первой части

Мы научились решать при неопределённых действиях. После перерыва — неопределённость состояния и вычисление порогов уверенности.

ЧАСТЬ 2

Когда неизвестно само состояние

POMDP, убеждение, структура функции ценности и расчёт порогов принятия решений.

12.8 Убеждение и его обновление

$$b'(s') = \eta \cdot O(s', a, o) \cdot \sum_s T(s, a, s') \cdot b(s)$$

- Убеждение b — распределение вероятностей на состояниях
- Обновление по формуле Байеса при действии a и наблюдении o
- η — нормировочный множитель
- **Теорема:** убеждение — достаточная статистика истории


POMDP сводится к MDP на симплексе распределений

$$V(b) = \max_{\alpha \in \Gamma} \langle \alpha, b \rangle$$

- Кусочно-линейна и выпукла (Смолвуд и Сондик, 1973)
- Доказательство индукцией: нормировочный множитель сокращается
- Γ_{k+1} строится из Γ_k комбинациями по действиям и наблюдениям
- $|\Gamma_{k+1}| \leq |A| \cdot |\Gamma_k|^{|\Omega|}$ — дважды экспоненциальный рост

Выпуклость означает: определённость выгоднее неопределённости

12.9

Кусочно-линейная выпуклая $V(b)$ 

Из выпуклости следует, что политика сама порождает действия сбора информации.

“

Из выпуклости следует: оптимальная политика POMDP сама порождает действия сбора информации.

Робот решит подъехать и посмотреть внимательнее, если это окупится

12.10 Постановка для примера А

- Типы: болт, гайка, посторонний предмет
- Действия: `look` (0,5 с), `look\_closer` (4 с), `place\_bolt`, `place\_nut`, `skip`
- Матрица ошибок `look`: диагональ 0,70; `look\_closer`: диагональ 0,94
- Верная укладка +20; неверная –50; пропуск целевого –10
- Априорное убеждение $b_0 = (0,4; 0,4; 0,2)$

12.11 Расчёт после наблюдения obs_bolt

0,718

убеждение $b_1(bolt)$ после
первого наблюдения

0,26

ожидаемая выгода
немедленной укладки

11,07

ожидаемая ценность
дополнительного наблюдения

×42

во столько раз наблюдение
выгоднее

- Уверенность 0,72 интуитивно кажется высокой
- Ожидаемая выгода при штрафе 50 практически нулевая

12.12


Порог уверенности выводится, а не назначается

$$20\beta - 50(1-\beta) \geq 16 \Rightarrow \beta \geq 0,943$$

- При штрафе –50 укладывать без уточнения следует лишь при уверенности выше 0,94
- При штрафе –10 порог падает до 0,867
- При штрафе –200 порог поднимается до 0,982
- В главе 1 мы взяли 0,8 «на глаз» — занижено на 14 процентных пунктов

Пороги не являются свойством классификатора. Они являются свойством задачи

12.12 Порог от стоимости ошибки



Порог 0,8 из главы 1 занижен на 14 процентных пунктов.

? Применяем

Ошибка укладки стоит 200 (нужно разбирать всю паллету). Классификатор даёт 0,95. Действовать или уточнять?

A Действовать: 0,95 — очень высокая уверенность

B Уточнять: порог при штрафе 200 составляет 0,982

C Зависит от времени уточнения

D Вторым и третьим варианты одновременно

? Применяем

Ошибка укладки стоит 200 (нужно разбирать всю паллету). Классификатор даёт 0,95. Действовать или уточнять?

A Действовать: 0,95 — очень высокая уверенность

B Уточнять: порог при штрафе 200 составляет 0,982

C Зависит от времени уточнения

D Второй и третий варианты одновременно

Ответ. Четвёртый: порог 0,982 вычислен при данной стоимости наблюдения; при более дорогом наблюдении он сдвинется. Но при указанных условиях 0,95 недостаточно.

12.13 Приближённые методы POMDP

Метод	Идея	Ограничение
QMDP	предполагает, что состояние станет наблюдаемым	не порождает действий сбора информации
PBVI, SARSOP	α -векторы в конечном множестве убеждений	офлайн, до тысяч состояний
POMCP, DESPOT	поиск по дереву методом Монте-Карло, частицы	онлайн, решает «здесь и сейчас»

Уровень миссии — SARSOP; тактические решения в реальном времени — POMCP с бюджетом 50–200 мс

12.14 Связь с другими главами

- **GSPN (гл. 5):** сеть без управления; MDP добавляет выбор — управляемые стохастические сети
- **Надёжность (гл. 16):** MDP обслуживания даёт обоснованный график вместо регламентного
- **Безопасность (гл. 9):** оптимальная политика не гарантирует безопасности
- MDP оптимизирует ожидание; редкое катастрофическое событие мало влияет на ожидание
- Отсюда — обязательность работы политики под защитным слоем

Ключевая идея

Формально это выражается концепцией щита: защитный автомат, синтезированный методами глав 3 и 8, отфильтровывает небезопасные действия до того, как они будут применены.

12.15 Обучение с подкреплением: пять ограничений

- **Данные:** 10^5 – 10^8 взаимодействий; миллион захватов по 10 с — 116 суток
- **Нет гарантий:** обученная политика не сопровождается доказательством свойств
- **Непредсказуемость вне распределения:** поведение при новых входах произвольно
- **Задание вознаграждения** не проще прямого программирования поведения
- **Нет объяснимости:** «сеть так научилась» не является обоснованием при приёме

12.16 Где обучение с подкреплением уместно


- Низкоуровневые навыки с трудно моделируемой физикой: вставка с зазором, деформируемые объекты
- Настройка параметров существующих алгоритмов, а не порождение поведения с нуля
- Оптимизация диспетчерских решений в симуляции, где ошибка не приводит к аварии
- Узкая область применения, легко ограничиваемая
- **Всегда** под независимым защитным слоем

Ключевая идея

$a = \pi_{RL}(s)$, если $a \in \text{Safe}(s)$; иначе $a = \pi_{\text{safe}}(s)$. Свойства безопасности гарантируются синтезом щита и не зависят от качества обучения.

12.16 Щит над обученной политикой

Щит: обученная политика допускается только под защитным слоем



Интеллектуальный компонент не может отвечать за безопасность

Гарантии безопасности обеспечивает синтез щита и не зависят от качества обучения.

12.17 Инструменты

Инструмент	Назначение
POMDPs.jl	единый интерфейс MDP/POMDP, SARSOP, POMCP, QMDP
pomdp-py	POMDP-моделирование и онлайн-решатели на Python
PRISM, Storm	вероятностная проверка моделей, синтез стратегий
MDPtoolbox	классические алгоритмы MDP
Stable-Baselines3	обучение с подкреплением

*PRISM и Storm позволяют ****доказать**** вероятностные свойства — прямое применение в главе 16*

“

Уверенность 0,72 не означает «скорее всего верно». Она означает «ожидаемая выгода почти ноль при штрафе 50».

Числа обретают смысл только вместе со стоимостями

Выводы

- 1 Неопределённость — часть задачи; перепланирование выбрасывает накопленную информацию
- 2 Оператор Беллмана — сжатие с коэффициентом γ ; отсюда существование, единственность и сходимость
- 3 Оптимум достигается на детерминированной стационарной политике — таблице «состояние $\rightarrow$ действие»
- 4 Убеждение — достаточная статистика; функция ценности кусочно-линейна и выпукла
- 5 Выпуклость влечёт: оптимальная политика сама порождает действия сбора информации
- 6 Пороги уверенности выводятся из стоимостей ошибок, а не назначаются
- 7 Обучение с подкреплением применимо к узким низкоуровневым навыкам и всегда под щитом

Вопросы для самопроверки

1. Что означает марковское свойство и что делать при его нарушении?
2. Докажите сжимаемость оператора Беллмана; где используется нормировка?
3. Почему достаточно детерминированных стационарных политик?
4. Сравните итерацию по ценности и по политике
5. Выведите формулу обновления убеждения; какова роль нормировочного множителя?
6. Докажите кусочную линейность и выпуклость функции ценности POMDP
7. Какой содержательный вывод следует из выпуклости?
8. Почему QMDP не порождает действий сбора информации?
9. Почему порог уверенности — свойство задачи, а не классификатора?
10. Сформулируйте принцип щита и объясните, почему он не подлежит обсуждению